


## **VARIABLES ALEATORIAS**

ALAN REYES-FIGUEROA  
APRENDIZAJE ESTADÍSTICO

(AULA 02) 10.ENERO.2024

# Variables aleatorias



## Definición

Sea  $(\Omega, \mathcal{F}, \mathbb{P})$  un espacio de probabilidad. Una **variable aleatoria** (v.a.) es una función medible  $X : \Omega \rightarrow \mathbb{R}$ .

Aquí medible significa que si  $X : (\Omega, \mathcal{F}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}), \mu)$ , entonces la preimagen de cualquier elemento en  $\mathcal{B}(\mathbb{R})$  es un elemento de  $\mathcal{F}$ . Esto es,  $X^{-1}$  lleva conjuntos medibles de  $\mathbb{R}$  (bajo la medida de Lebesgue  $\mu$ ), a conjuntos medibles en  $\mathcal{F}$  (bajo la probabilidad  $\mathbb{P}$ ).

A los elementos de  $\mathcal{B}(\mathbb{R})$  se les llama los *borelianos* de  $\mathbb{R}$ .

# Variables aleatorias

## Ejemplo

Elegimos al azar una persona de un grupo. De cada persona tenemos un registro de su edad, altura, peso, ...

Mapeamos cada persona  $\omega$  a  $X(\omega) = (X_1(\omega), \dots, X_d(\omega))$ , donde por ejemplo  $X_1(\omega)$  representa su edad,  $X_2(\omega)$  su altura, etc.

Si el grupo de personas corresponde a una base de datos, entonces  $X$  regresa los campos de interés de cada registro. Las variables  $X_1, \dots, X_d$  son variables aleatorias.

En este ejemplo llamaremos a  $X$  como una variable aleatoria (en realidad  $X$  es un vector aleatorio).

# Variables aleatorias

## Observaciones:

- una variable aleatoria determina una relación determinística.
- una variable aleatoria induce una función de probabilidad.

Definimos  $\mathbb{P}_X(\cdot)$  como

$$\mathbb{P}_X(A) = P(\{\omega \in \Omega : X(\omega) \in A\}).$$

Escribimos  $\mathbb{P}_X(\cdot)$  como  $\mathbb{P}(\cdot)$ .

Por ejemplo,  $\mathbb{P}(X = x)$  denota  $\mathbb{P}_X(X = x) = \mathbb{P}(\{\omega : X(\omega) = x\})$ .

$\mathbb{P}(X < a)$  denota  $\mathbb{P}_X(X < a) = \mathbb{P}(\{\omega : X(\omega) < a\})$ .

# Variables aleatorias

Caso discreto:

## Definición

Diremos que  $X$  es una variable aleatoria **discreta** si su contradominio  $I = X(\Omega)$  es enumerable y  $\mathbb{P}_X(i) = \mathbb{P}(X = i)$  existe para cada  $i \in I$ .  
(Comunmente se identifica el contradominio  $I$  con los naturales ).

## Definición

Al conjunto de probabilidades  $\{\mathbb{P}_X(i)\}_{i \in I}$  le llamamos la **distribución** de  $X$ .  
(En general, a  $\mathbb{P}_X$  se le llama la **función de masa de probabilidad**).

## Definición

Si  $X \in \mathbb{R}$ , llamamos a  $F_X(x) = \mathbb{P}(X \leq x)$  la **función de distribución** (acumulativa) de  $X$ .

# Variables aleatorias

Caso continuo:

## Definición

Considere la función  $F : \mathbb{R} \rightarrow \mathbb{R}$ , dada por

$$F_X(t) = \mathbb{P}(X \leq t).$$

Diremos que  $X$  es una variable aleatoria **continua** si existe una función no-negativa  $f_X : \mathbb{R} \rightarrow \mathbb{R}$ , tal que

$$F_X(t) = \mathbb{P}(X \leq t) = \int_{-\infty}^t f_X(x) dx.$$

## Definición

En ese caso, a la función  $f_X$  le llamamos la **densidad de probabilidad** de  $X$ .

**Obs!** La función de densidad  $f_X$  no tiene por qué ser continua.

Ya sea en el caso discreto o continuo,

## Definición

Si  $x \in \mathbb{R}$ , llamamos a  $F_X(x) = \mathbb{P}(X \leq x)$  la **función de distribución** (acumulativa) de  $X$ .

En general, definimos la función de distribución para un vector aleatorio  $X = (X_1, \dots, X_d)$  como

$$F_X(x_1, \dots, x_d) = \mathbb{P}(X_1 \leq x_1, \dots, X_d \leq x_d), \quad \forall (x_1, \dots, x_d) \in \mathbb{R}^d.$$

En este caso, llamamos a  $F_X$  la **función de distribución conjunta** de  $X_1, \dots, X_d$ .

# Propiedades

## Propiedades de $\mathbb{P}_X$ y $f_X$ :

Propiedad	$X$ discreta	$X$ continua
no-negativa	$\mathbb{P}_X(A) \geq 0$	$f_X(x) \geq 0$
suma total	$\sum_x \mathbb{P}_X(x) = 1$	$\int_{\mathbb{R}} f_X(x) dx = 1$
relación entre $f_X$ y $F_X$	$\mathbb{P}(X = x) = F_X(x) - F_X(x^-)$	$f_X(x) = \frac{d}{dx} F_X(x)$
relación entre $f_X$ y $F_X$	$F_X(x) = \sum_{t \leq x} \mathbb{P}(X = t)$	$F_X(x) = \int_{-\infty}^x f_X(t) dt$



# Propiedades

## Propiedades de $F_X$ :

Propiedad	$X$ discreta	$X$ continua
limitada	$0 \leq F_X(x) \leq 1$	$0 \leq F_X(x) \leq 1$
monotonía	$F_X$ no-decreciente	$F_X$ no-decreciente
límite inferior	$F_X(t) = 0, \forall t < \min_{x \in I(\Omega)}$	$\lim_{x \rightarrow -\infty} F_X(x) = 0$
límite superior	$F_X(t) = 1, \forall t \geq \max_{x \in I(\Omega)}$	$\lim_{x \rightarrow +\infty} F_X(x) = 1$

Además,  $F_X$  tiene la propiedad de semi-continuidad inferior:  $F_X$  es continua por la derecha, con límites por la izquierda.

# Variables aleatorias discretas

- distribución Uniforme  $U[a..b]$ ,
- distribución Bernoulli  $Ber(p)$ ,
- distribución Binomial  $Binom(n, p)$ ,
- distribución Geométrica  $Geom(p)$ ,
- distribución Poisson  $Poisson(\lambda)$ ,
  
- distribución Rademacher  $Rad(p)$ ,
- distribución Binomial Negativa  $NB(r, p)$ ,
- distribución Hipergeométrica  $Hypergeometric(N, K, n)$ .


# Variables aleatorias discretas

## 1. Distribución Uniforme

$$X \sim U[a..b] \Leftrightarrow \mathbb{P}(X = k) = \frac{1}{b-a+1}, \text{ para } k = a, a+1, \dots, b.$$

### Obs.

- Esta distribución depende de dos parámetros (de localización):  $a$  y  $b$ .
- El caso  $a = b$ , con  $\mathbb{P}(X = a = b) = 1$  se llama una v.a. *degenerada*.




# Variables aleatorias discretas

## 2. Distribución Bernoulli

$$X \sim \text{Ber}(p) \Leftrightarrow \mathbb{P}(X = 1) = p, \mathbb{P}(X = 0) = 1 - p, \text{ para } 0 \leq p \leq 1.$$

### Obs.

- La distribución es simétrica si, y sólo si,  $p = 1/2$ .
- $\mathbb{E}(X) = p$ ,  $\text{Var}(X) = p(1 - p)$ .



# Variables aleatorias discretas

La distribución Bernoulli tiene una hermana gemela: la distribución de Rademacher.

$$X \sim \text{Rad}(p) \Leftrightarrow \mathbb{P}(X = 1) = p, \mathbb{P}(X = -1) = 1 - p, \text{ para } 0 \leq p \leq 1.$$

## Preguntas:

- ¿Cuál es la media y varianza de la distribución  $\text{Rad}(p)$ .
- Sean  $X, Y$  v.a., con  $X \sim \text{Ber}(p)$  y  $Y \sim \text{Rad}(p)$ . Escribir  $X$  en términos de  $Y$ , y  $Y$  en términos de  $X$ .

La distribución de Bernoulli es importante para escribir situaciones donde se cuenta la ocurrencia de eventos. La variable  $X \sim \text{Ber}(p)$  cuenta o indica la ocurrencia del evento de interés.

# Variables aleatorias discretas

## 3. Distribución Binomial


$$X \sim \text{Binom}(n, p) \Leftrightarrow \mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \text{ para } k = 0, 1, \dots, n.$$

Interpretación: Si  $\{X_i\}_{i=1}^n$  son v.a. i.i.d. con  $X_i \sim \text{Ber}(p)$ , entonces

$$X = \sum_{i=1}^n X_i \sim \text{Binom}(n, p).$$

### Obs.

- La distribución es simétrica si, y sólo si,  $p = 1/2$ .
- $\mathbb{E}(X) = np$ ,  $\text{Var}(X) = np(1-p)$ .



# Variables aleatorias discretas


## 4. Distribución Geométrica

$$X \sim \text{Geom}(n, p) \Leftrightarrow \mathbb{P}(X = k) = p(1 - p)^{k-1}, \text{ para } k = 1, 2, 3, \dots$$

Interpretación: Si  $\{X_i\}_{i=1}$  son v.a. *i.i.d.* con  $X_i \sim \text{Ber}(p)$ , entonces  
 $X =$  el momento del primer éxito en  $\{X_i\} \sim \text{Geom}(p)$ .

### Obs.

- La probabilidad va decayendo en forma geométrica con  $k$ .
- $\mathbb{E}(X) = \frac{1}{p}$ .



# Variables aleatorias discretas

## 5. Distribución Poisson


$$X \sim \text{Poisson}(\lambda) \Leftrightarrow \mathbb{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \text{ para } k = 0, 1, 2, \dots$$

En este caso,

$\mathbb{P}(X = k)$  = probabilidad de que el evento de interés ocurra  $k$  veces.

### Obs.

- Cuenta el número de llegadas de un proceso con tiempos exponenciales  $\text{Exp}(\lambda)$ .
- $\mathbb{E}(X) = \lambda$ . Representa el número esperado de veces que ocurra el fenómeno durante un intervalo dado.





# Variables aleatorias continuas

- distribución Uniforme  $U[a..b]$ ,
- distribución Normal  $\mathcal{N}(\mu, \sigma^2)$ ,
- distribución Lognormal  $\mathcal{LN}(\mu, \sigma^2)$ ,
  
- distribución Exponencial  $Exp(\lambda)$ ,
- distribución Erlang  $Erlang(n, \lambda)$ ,
- distribución Gamma  $\Gamma(\alpha, \beta)$ ,
- distribución Beta  $Beta(\alpha, \beta)$ ,
  
- distribución Weibull,
- distribución Pareto,
- distribuciones de valores extremos.

# Variables aleatorias continuas

## 1. Distribución Uniforme

$$X \sim U[a..b] \Leftrightarrow f_X(t) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(t).$$

**Obs.** Aquí la función  $\mathbf{1}_{[a,b]}$  es una *función indicadora* o *función característica*, que indica cuál es el soporte de la distribución.

Recordemos que para cualquier subconjunto  $A \subseteq \mathbb{R}$

$$\mathbf{1}_A(t) = \begin{cases} 1, & t \in A; \\ 0, & t \notin A. \end{cases}$$

Preguntas: ¿Cuál es la función de distribución  $F_X$ ? ¿ $\mathbb{E}(X)$ ,  $\text{Var}(X)$ ?

2. Distribución Exponencial Dado un parámetro  $\lambda > 0$ , la distribución exponencial tiene densidad

$$f_X(t) = \lambda e^{-\lambda t} \mathbf{1}_{[0, \infty)}(t), \quad F_X(t) = (1 - e^{-\lambda t}) \mathbf{1}_{[0, \infty)}(t).$$

**Obs.**

- $\mathbb{E}(X) = \frac{1}{\lambda}$  y  $\text{Var}(X) = \frac{1}{\lambda^2}$ .
- En ocasiones, se parametriza en términos de su valor esperado  $\theta = \frac{1}{\lambda}$ :

$$f_X(t) = \frac{1}{\theta} e^{-t/\theta} \mathbf{1}_{[0, \infty)}(t).$$

# Variables aleatorias continuas


3. Distribución Normal Dados dos parámetros  $\mu \in \mathbb{R}$ ,  $\sigma > 0$ , la distribución normal tiene densidad

$$f_X(t) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \mathbf{1}_{\mathbb{R}}(t).$$

**Obs.**

- $\mathbb{E}(X) = \mu$  y  $\text{Var}(X) = \sigma^2$ .
- La distribución es simétrica alrededor de  $\mu$ .
- $X$  no tiene una función de distribución elemental

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$



## Propiedades

1. Si  $X \sim \mathcal{N}(\mu, \sigma^2)$ , se tiene que  $Z = \frac{X-\mu}{\sigma} \sim \mathcal{N}(, 1)$ .
2. Si  $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$  y  $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$ , y  $X_1, X_2$  son independientes, entonces

$$X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

3. Si  $X \sim \mathcal{N}(\mu, \sigma^2)$ , se tiene que  $-X \sim \mathcal{N}(-\mu, \sigma^2)$ .
4. En general, si  $X \sim \mathcal{N}(\mu, \sigma^2)$ , y  $a, b \in \mathbb{R}$ , entonces  $Y = aX + b$  es normal, con

$$Y \sim \mathcal{N}(a\mu + b, a^2\sigma^2).$$

# Teoremas importantes

## Teorema (Desigualdad de Markov)

Si  $X$  es una v.a. no-negativa,  $a > 0$ , entonces

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}.$$

## Teorema (Desigualdad de Tchebyshev)

Si  $X$  es una v.a. con  $\mathbb{E}(X)$  y  $\text{Var}(X)$  finitas,  $a > 0$ , entonces

$$\mathbb{P}(|X - \mathbb{E}(X)| \geq a) \leq \frac{\text{Var}(X)}{a^2}.$$

# Teoremas importantes

## Teorema (Ley débil de los números grandes)

Sean  $X_1, X_2, \dots, X_n$  variables aleatorias i.i.d., con  $\mathbb{E}(X_i) < \infty$ . Entonces, para todo  $\epsilon > 0$


$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{X_1 + X_2 + \dots + X_n}{n} - \mathbb{E}(X)\right| > \epsilon\right) = 0.$$

### Interpretación:

Se repite el experimento  $n$  veces, con resultados  $X_i$ .

$\mathbb{E}(X) = \mathbb{P}(A)$ , entonces  $\frac{X_1 + X_2 + \dots + X_n}{n}$  es el porcentaje de veces que ocurrió  $A$ .

La ley débil dice que el porcentaje de veces que  $A$  ocurrió en  $n$  repeticiones se aproxima a  $\mathbb{E}(X)$ .



# Teoremas importantes

## Teorema (Teorema Central de Límite)

Sean  $X_1, X_2, \dots, X_n$  variables aleatorias i.i.d., con  $\mathbb{E}(X_i) = \mu$ ,  $\text{Var}(X_i) = \sigma^2$  finitas. Entonces

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{S_n/n - \mu}{\sigma/\sqrt{n}} \leq x\right) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt.$$

### Consecuencias:

$$\frac{S_n}{n} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

o equivalentemente

$$X_1 + \dots + X_n = S_n \sim \mathcal{N}(n\mu, n\sigma^2).$$

